Diplomado Ciencia de Datos

Abril, 2026

PROYECTO 4: CLASIFICACIÓN - BPC

IDC Ingeniería de Confiabilidad

Universidad Tecnológica de Pereira

Proyecto 4. Machine Learning para Clasificación — BPC Estación de Bombeo

Entrega de Dataset · Industria de hidrocarburos

Entregado por	*IDC Ingeniería de Confiabilidad S.A.S. — División de Analítica Predictiva*
Proyecto asociado	*Proyecto 4. Machine Learning para Clasificación — BPC Estación de Bombeo*
Destinatario	*Equipo de estudiantes asignado al Proyecto 4*
Archivo entregado	*Data_BPC_processed.csv/ Pesos Ponderados – Proyecto 4*
Repositorio	*https://github.com/IDC-ANALYTICS/Datasets-for-Notebooks/tree/main/PROYECTO%20INTEGRADOR%20UTP*

1. Propósito del Dataset

Este dataset ha sido preparado por IDC Ingeniería de Confiabilidad S.A.S. para soportar el desarrollo del Proyecto 4. Contiene registros de vibración medidos en los cojinetes del conjunto motor-bomba-variador de una bomba centrífuga en una estación de bombeo de hidrocarburos. Cada registro está etiquetado con el tipo de crudo trasegado en el momento de la medición (columna Batch). El dataset permite desarrollar modelos de clasificación supervisada que identifiquen el tipo de crudo a partir de las firmas vibratorias del equipo.

2. Descripción General del Dataset

Atributo	Detalle
Activo	Bomba centrífuga con motor eléctrico y variador de frecuencia — Estación de bombeo de hidrocarburos
Industria	Industria de hidrocarburos — Operaciones de transporte
Registros (filas)	88.121
Variables (columnas)	26 (24 features vibratorios + Timestamp + Batch)
Período cubierto	2025-12-10 al 2025-12-11 (aprox. 24 horas)
Frecuencia de muestreo	1 segundo (aprox.)
Variable objetivo	Batch — tipo de crudo: CASTILLA (42%), RUBIALES (23%), MEZCLA (35%)
Archivo entregado	Data_BPC_processed.csv
Columna de tiempo	Timestamp
Formato	CSV, codificación UTF-8

3. Archivos Entregados

Archivo	Descripción
Data_BPC_processed.csv	Dataset de vibración del conjunto motor-bomba-variador con etiquetas de tipo de crudo trasegado (Batch). Cubre aproximadamente 24 horas de operación con tres tipos de crudo: CASTILLA, RUBIALES y MEZCLA.
Pesos Ponderados - Proyecto4.xlsx	Archivo de pesos ponderados de referencia. Contiene los pesos de las 24 variables vibratorias de la BPC y los parámetros de la assessment function univariable.

4. Diccionario de Variables

Los puntos de medición se nombran con la convención: [Posición] [Componente] \ [Sensor-ID] \ [Magnitud]. Las posiciones son: LL = Lado Libre, LA = Lado Acople, LM = Lado Motor (del variador), LB = Lado Bomba (del variador). Los sensores de desplazamiento pico a pico corresponden a sondas de proximidad (inductivas); los de aceleración y velocidad RMS corresponden a acelerómetros.

Variable en el dataset	Descripción	Unidades	Tipo / Rol
Timestamp	Marca de tiempo del registro	—	Datetime
LL MOTOR\VIX1-74447\Desplazamiento Pico a Pico	Desplazamiento pico a pico — dirección X, cojinete LL del motor	µm	Feature
LL MOTOR\VIY1-74448\Desplazamiento Pico a Pico	Desplazamiento pico a pico — dirección Y, cojinete LL del motor	µm	Feature
LA MOTOR\VIX2-74445\Desplazamiento Pico a Pico	Desplazamiento pico a pico — dirección X, cojinete LA del motor	µm	Feature
LA MOTOR\VIY2-74446\Desplazamiento Pico a Pico	Desplazamiento pico a pico — dirección Y, cojinete LA del motor	µm	Feature
LA BOMBA\VIX3-74442\Desplazamiento Pico a Pico	Desplazamiento pico a pico — dirección X, cojinete LA de la bomba	µm	Feature
LA BOMBA\VIY3-74441\Desplazamiento Pico a Pico	Desplazamiento pico a pico — dirección Y, cojinete LA de la bomba	µm	Feature
LL BOMBA\VIX4-74443\Desplazamiento Pico a Pico	Desplazamiento pico a pico — dirección X, cojinete LL de la bomba	µm	Feature
LL BOMBA\VIY4-74444\Desplazamiento Pico a Pico	Desplazamiento pico a pico — dirección Y, cojinete LL de la bomba	µm	Feature
LA MOTOR\AC LA H MOTOR\Aceleración Rms [g]	Aceleración RMS — dirección horizontal, cojinete LA del motor	g	Feature
LA MOTOR\AC LA H MOTOR\Velocidad Rms [mm/s]	Velocidad RMS — dirección horizontal, cojinete LA del motor	mm/s	Feature
LA MOTOR\AC LA A MOTOR\Aceleración Rms [g]	Aceleración RMS — dirección axial, cojinete LA del motor	g	Feature
LA MOTOR\AC LA A MOTOR\Velocidad Rms [mm/s]	Velocidad RMS — dirección axial, cojinete LA del motor	mm/s	Feature

LA BOMBA\AC LA A BOMBA\Aceleración Rms [g]	Aceleración RMS — dirección axial, cojinete LA de la bomba	g	Feature
LA BOMBA\AC LA A BOMBA\Velocidad Rms [mm/s]	Velocidad RMS — dirección axial, cojinete LA de la bomba	mm/s	Feature
LA BOMBA\AC LA H BOMBA\Aceleración Rms [g]	Aceleración RMS — dirección horizontal, cojinete LA de la bomba	g	Feature
LA BOMBA\AC LA H BOMBA\Velocidad Rms [mm/s]	Velocidad RMS — dirección horizontal, cojinete LA de la bomba	mm/s	Feature
LM VARIADOR\AC LM H VARIADOR\Aceleración Rms [g]	Aceleración RMS — dirección horizontal, Lado Motor del variador de frecuencia	g	Feature
LM VARIADOR\AC LM H VARIADOR\Velocidad Rms [mm/s]	Velocidad RMS — dirección horizontal, Lado Motor del variador de frecuencia	mm/s	Feature
LB VARIADOR\AC LB H VARIADOR\Aceleración Rms [g]	Aceleración RMS — dirección horizontal, Lado Bomba del variador de frecuencia	g	Feature
LB VARIADOR\AC LB H VARIADOR\Velocidad Rms [mm/s]	Velocidad RMS — dirección horizontal, Lado Bomba del variador de frecuencia	mm/s	Feature
LL MOTOR\AC LL H MOTOR\Aceleración Rms [g]	Aceleración RMS — dirección horizontal, cojinete LL del motor	g	Feature
LL MOTOR\AC LL H MOTOR\Velocidad Rms [mm/s]	Velocidad RMS — dirección horizontal, cojinete LL del motor	mm/s	Feature
LL BOMBA\AC LL H BOMBA\Aceleración Rms [g]	Aceleración RMS — dirección horizontal, cojinete LL de la bomba	g	Feature
LL BOMBA\AC LL H BOMBA\Velocidad Rms [mm/s]	Velocidad RMS — dirección horizontal, cojinete LL de la bomba	mm/s	Feature
Batch	Tipo de crudo trasegado — variable objetivo de clasificación. Valores: CASTILLA, RUBIALES, MEZCLA	—	Target (variable objetivo)

5. Calidad del Dato Conocida

- Nombres de columna con barras invertidas: los nombres de las columnas vibratorias usan el separador '\' (barra invertida). Al cargar con pandas, los nombres se conservan tal cual; el equipo debe usar comillas o renombrar las columnas para facilitar la manipulación en el código.
- Período muy corto (24 horas): el dataset cubre solo un día de operación. Esto limita la variabilidad temporal capturada. El equipo debe tener en cuenta este contexto al diseñar el esquema de validación y al generalizar conclusiones.
- Desbalance de clases: la distribución es CASTILLA 42%, MEZCLA 35%, RUBIALES 23%. El equipo debe cuantificar este desbalance y documentar la estrategia de manejo adoptada (class_weight, SMOTE, umbral de decisión, etc.).
- Transiciones entre tipos de crudo: en los cambios de Batch puede haber registros en estado de transición que no son representativos de ninguna clase de forma pura. El equipo debe identificar y analizar estos períodos.
- Variables del variador de frecuencia: los puntos LM VARIADOR y LB VARIADOR presentan aceleraciones más altas (0.76–2.30 g) en comparación con los cojinetes del motor y la bomba. Esto es esperable dado el origen electromagnético de las vibraciones en el variador.

6. Acceso al Dataset

Los archivos de este proyecto están disponibles públicamente en el repositorio GitHub de IDC Analytics. El repositorio está organizado con la misma estructura de carpetas que la entrega local: cada proyecto tiene su propia subcarpeta con el mismo nombre, y dentro de ella se encuentran los archivos CSV de datos y el documento de entrega.

Repositorio público:

https://github.com/IDC-ANALYTICS/Datasets-for-Notebooks/tree/main/PROYECTO%20INTEGRADOR%20UTP

Los archivos CSV pueden descargarse individualmente desde la interfaz web de GitHub (botón "Download raw file") o mediante la URL de descarga directa (raw) de cada archivo. También es posible clonar el repositorio completo con el comando: git clone https://github.com/IDC-ANALYTICS/Datasets-for-Notebooks.git

7. Consideraciones para el Uso en el Proyecto

- Todas las features son señales vibratorias. No existen variables de proceso (presión, caudal, temperatura de fluido) en este dataset. El poder de clasificación proviene exclusivamente de las diferencias en la firma vibratoria de la bomba-motor al trasegar distintos tipos de crudo.
- El análisis exploratorio diferencial por clase (EDA por tipo de Batch) es el primer paso obligatorio. El equipo debe visualizar y comparar las distribuciones de cada feature por clase antes de entrenar cualquier modelo.
- El esquema de validación debe respetar la secuencia temporal. No usar partición aleatoria. Dada la corta duración del dataset, se recomienda una estrategia de validación por bloques contiguos o leave-one-batch-out.
- Se deben comparar al menos tres algoritmos de clasificación. La interpretabilidad (SHAP, importancia de variables) es un requisito no negociable: el equipo debe explicar qué sensores y magnitudes son más discriminantes entre los tres tipos de crudo.
- La clase MEZCLA puede representar una combinación variable de CASTILLA y RUBIALES. El equipo debe explorar si esta clase es separable de las otras dos y documentar los hallazgos.

8. Restricciones de Uso

- Uso académico exclusivo en el contexto del Diplomado de Ciencia de Datos. No distribuir sin autorización de IDC Ingeniería de Confiabilidad S.A.S.
- Información confidencial de cliente real de la industria de hidrocarburos. No divulgar el nombre del operador, la estación ni datos identificables.
- No implementar el modelo en sistemas de control o producción sin revisión técnica y aprobación del operador.
- No modificar el archivo fuente. Toda transformación debe realizarse en el entorno de análisis y documentarse en el Notebook.

9. Archivo de Pesos Ponderados — Sistema de Cuantificación de Desempeño

El archivo Pesos Ponderados - Proyecto4.xlsx contiene los parámetros del sistema de cuantificación de desempeño por pesos ponderados visto en clase. El sistema asigna a cada una de las 24 variables de condición del activo un peso relativo (columna Pesos) que refleja su importancia en la evaluación global del estado del equipo. La columna División contiene el peso normalizado (Pesos ÷ ΣPesos = 79.8), de modo que su suma es igual a 1. El índice de desempeño global se obtiene como la suma ponderada de los índices individuales de cada variable calculados mediante la assessment function univariable.

Las columnas Alarma (High) y Crítico (HIGH HIGH) definen los umbrales de alerta de cada variable. Los parámetros H, HH y V0 corresponden a la assessment function univariable: V0 es el valor de referencia (condición óptima), H el umbral de alarma

y HH el umbral crítico. El equipo debe completar estos parámetros basándose en los datos históricos y los criterios de norma o experto aplicables al activo.

ID	Variable	Pesos	División
1	Desplazamiento Pico a Pico VIX1 — LL Motor [µm]	3.0	0.037594
2	Desplazamiento Pico a Pico VIY1 — LL Motor [µm]	3.0	0.037594
3	Desplazamiento Pico a Pico VIX2 — LA Motor [µm]	3.2	0.040100
4	Desplazamiento Pico a Pico VIY2 — LA Motor [µm]	3.2	0.040100
5	Desplazamiento Pico a Pico VIX3 — LA Bomba [µm]	4.0	0.050125
6	Desplazamiento Pico a Pico VIY3 — LA Bomba [µm]	4.0	0.050125
7	Desplazamiento Pico a Pico VIX4 — LL Bomba [µm]	3.2	0.040100
8	Desplazamiento Pico a Pico VIY4 — LL Bomba [µm]	3.2	0.040100
9	Aceleración RMS — LA Motor Horizontal [g]	3.8	0.047619
10	Velocidad RMS — LA Motor Horizontal [mm/s]	3.2	0.040100
11	Aceleración RMS — LA Motor Axial [g]	3.8	0.047619
12	Velocidad RMS — LA Motor Axial [mm/s]	3.2	0.040100
13	Aceleración RMS — LA Bomba Axial [g]	4.8	0.060150
14	Velocidad RMS — LA Bomba Axial [mm/s]	3.8	0.047619
15	Aceleración RMS — LA Bomba Horizontal [g]	4.8	0.060150
16	Velocidad RMS — LA Bomba Horizontal [mm/s]	3.8	0.047619
17	Aceleración RMS — LM Variador Horizontal [g]	2.4	0.030075
18	Velocidad RMS — LM Variador Horizontal [mm/s]	2.0	0.025063
19	Aceleración RMS — LB Variador Horizontal [g]	2.4	0.030075
20	Velocidad RMS — LB Variador Horizontal [mm/s]	2.0	0.025063
21	Aceleración RMS — LL Motor Horizontal [g]	3.2	0.040100
22	Velocidad RMS — LL Motor Horizontal [mm/s]	2.8	0.035088
23	Aceleración RMS — LL Bomba Horizontal [g]	3.8	0.047619
24	Velocidad RMS — LL Bomba Horizontal [mm/s]	3.2	0.040100
	TOTAL	**79.8**	**1.000000**

Carlos Alberto Camacho Castaño
Analista de Desarrollos Predictivos

Juan Camilo Urango Pérez
Líder de Ingeniería e innovación